

Acurácia original por tipo de consulta (%)

DeepSeek-V4-Flash					Gemma-4-E4B				
	Direta	Ambígua	Distrator	Sem ferramenta		Direta	Ambígua	Distrator	Sem ferramenta
Baseline · 50 / full / native	87,5	47,5	75,0	100,0		75,0	37,5	73,8	100,0
10 ferramentas	93,8	68,8	81,2	100,0		68,8	37,5	75,0	100,0
30 ferramentas	87,5	50,0	75,0	100,0		68,8	37,5	75,0	100,0
random · 5 ferramentas	0,0	8,8	12,5	100,0		0,0	0,0	12,5	100,0
embedding · 5 ferramentas	98,8	60,0	88,8	100,0		87,5	43,8	75,0	100,0
hybrid · 5 ferramentas	100,0	68,8	83,8	100,0		87,5	50,0	75,0	100,0
two_stage · domínio	92,5	48,8	76,2	93,8		50,0	31,2	50,0	100,0
json_prompt	96,2	88,8	95,0	100,0		70,0	43,8	75,0	100,0
code_action	100,0	93,8	100,0	100,0		86,2	50,0	92,5	100,0

80 execuções por célula (16 consultas × 5). Em no_tool, a métrica original pode contar falhas de parsing como acertos.